

有明高専 情報システムコース
ゴーチュ研究室
内田陽太, 浦崎華瑠

「異常値を含むデータに対する
文脈情報統合の有効性に関する研究」
— 株価予測を題材とした検証 —

2025.10.22

目次

1. 背景と課題
2. 研究目的とプロセス
3. データの概要と特徴量
4. 目的変数と評価指標
5. 各モデルの概要
6. コード実装の概要
7. 予想
8. 研究結果
9. 考察
10. 今後の展望

1. 背景と課題

・背景

需給・市場・Web 履歴などあらゆるデータがログとして蓄積される現在、将来を見通す予測の必要性が一段と高まっている。

・課題

数値特徴だけでは、文脈依存的な「異常値」を説明することができない。

例：コロナショック、高市氏の総裁選出、トランプショック

高市氏の総裁選選出時
日経平均終値（10月6日）

47,944.76

+2175.26



図1. イベントによる異常値の例

引用：日経平均株価：チャート-Yahoo!ファイナンス
<https://finance.yahoo.co.jp/quote/998407.O/char>
(アクセス日10/14)

2. 研究目的とプロセス

研究目的

- ニュース情報を統合した株価予測モデルの検討

ニュースやイベントに含まれる文脈情報を数値データに統合し、異常値を「ノイズ」ではなく有用な情報として学習。性能を評価し、比較検証。

大規模時系列データの代表例である「**株価**」を題材とする。



2. 研究目的とプロセス

・研究の流れ

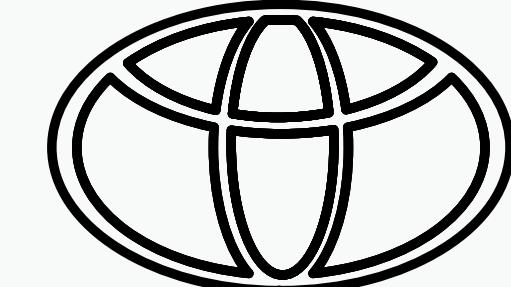
フェーズ1：数値特徴量による複数分類モデル構築

- └ 線形 (Logistic Regression)
- └ 木構造 (LightGBM)
- └ NN : ニューラルネットワーク (LSTM / Transformer)

上記の学習モデルを比較し、時系列データの予測に有効なモデルを調べる。

フェーズ2. 文脈情報の統合による汎化性能を評価

3. データの概要と特徴量

- ・対象銘柄： トヨタ自動車 (7203.T)
 - ・期間： 2001/01/01～2024/12/31
 - ・サンプリング単位： 日足 (データ数 n = 5305)
- 
- ・予測対象
 1. main(全体)： テストデータ全体の集合
 2. subset： テストデータ全体から、翌日リターン比上位10%のデータ集合

・特徴量

価格・リターン系 ret1/5/10/20(1/5/10/20日リターン)
 devMA5/20/60(移動平均乖離)

市場指標系 topix_ret1, nikkei_ret1(各指数の1日リターン)
 vix_ret1(恐怖指数の日次変化)

etc.

4. 目的変数と評価指標

・目的変数の定義

私たちが用いる目的変数は、株価の翌営業日の方向性を示した三値分類である。

以下にその目的変数を示す。

$$y_t = \begin{cases} 0 & (\text{下落}) \\ 1 & (\text{停滞}) \\ 2 & (\text{上昇}) \end{cases} \quad (1)$$

4. 目的変数と評価指標

ラベル生成の手順を以下に示す。

予測対象は、1日先($H = 1$)の累積リターンであり、次式で示される。

$$r_H(t) = \frac{Close_{t+H}}{Close_t} - 1 \quad (2)$$

これを、以下に示す当日のボラティリティに応じてスケールした動的閾値 τ により分類する。

$$\tau_t(H) = k_\tau \times \sigma_{20}(t) \times \sqrt{H} \quad (3)$$

$$\left(\begin{array}{l} \sigma_{20}(t) : \text{当日までの20日間のリターン標準偏差} \\ k_\tau : \text{ボラティリティに対する閾値スケール (定数)} \end{array} \right)$$

4. 目的変数と評価指標

(2)(3)式を利用し、私たちが使用した三値分類の定義を以下に示す。

$$y_t = \begin{cases} 0 & (r_H(t) < -\tau_t(H)) \\ 1 & (|r_H(t)| \leq \tau_t(H)) \\ 2 & (r_H(t) > \tau_t(H)) \end{cases} \quad (4)$$

4. 目的変数と評価指標

表 1. 具体例(翌日予測 $H = 1$)の場合

当日終値	翌日終値	$r_H(t)$	σ_{20}	$\tau_{t(H)}$	クラス
2000	2010	+0.5%	1.5%	0.45%	2(上昇)
2000	1999	-0.05%	1.5%	0.45%	1(停滞)
2000	1980	-1.0%	1.5%	0.45%	0(下落)

4. 目的変数と評価指標

・評価指標

多クラス分類ではクラス間の偏りを考慮する必要があり、「正解率」だけでは正しい評価はできない。

1. 混同行列

表2. 混同行列

予測\実際	下落(0)	停滞(1)	上昇(2)
下落(0)	TN	TN	FN
停滞(1)	TN	TN	FN
上昇(2)	FP	FP	TP

T: True

F: False

P: Positive

N: Negative

※上昇(2)をPositiveとしたとき

4. 目的変数と評価指標

混同行列を用いて、計算される指標には以下のようなものがある。

precision(適合率) ⇒ 予測したうち正しかった割合

recall(再現率) ⇒ 実際に正しい中で当てられた割合

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i}, \quad \text{Recall}_i = \frac{TP_i}{TP_i + FN_i} \quad (5)(6)$$

各クラスごとの「適合率」「再現率」の調和平均を示す、F1スコアがある。

$$F1_i = \frac{2 \times (\text{Precision}_i \times \text{Recall}_i)}{\text{Precision}_i + \text{Recall}_i} \quad (7)$$

4. 目的変数と評価指標

前述したF1スコアを多クラス分類に応用するために平均をとる。
F1スコアの平均をとったものをMacro-F1と呼ぶ。

$$\text{Macro-F1} = \frac{1}{3} \sum_{i=0}^2 \text{F1}_i \quad (8)$$

また、Macro-F1以外に、補助的にBalanced Accuracyも用いる。
これは、recall(再現率)だけをみることで、公平性を確認している。

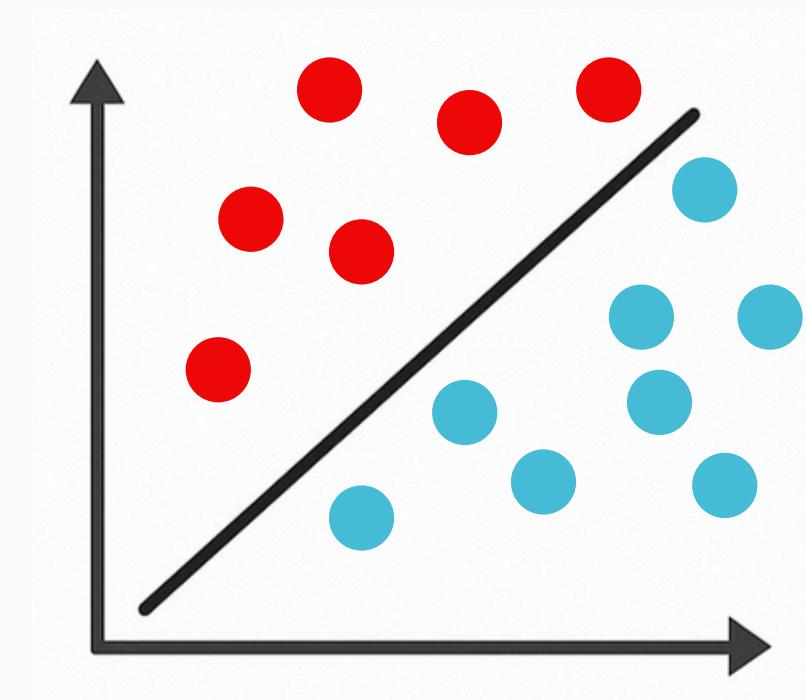
$$\text{Balanced Accuracy} = \frac{1}{3} \sum_{i=0}^2 \frac{TP_i}{TP_i + FN_i} \quad (9)$$

5. 各モデルの概要

- ・非NN系

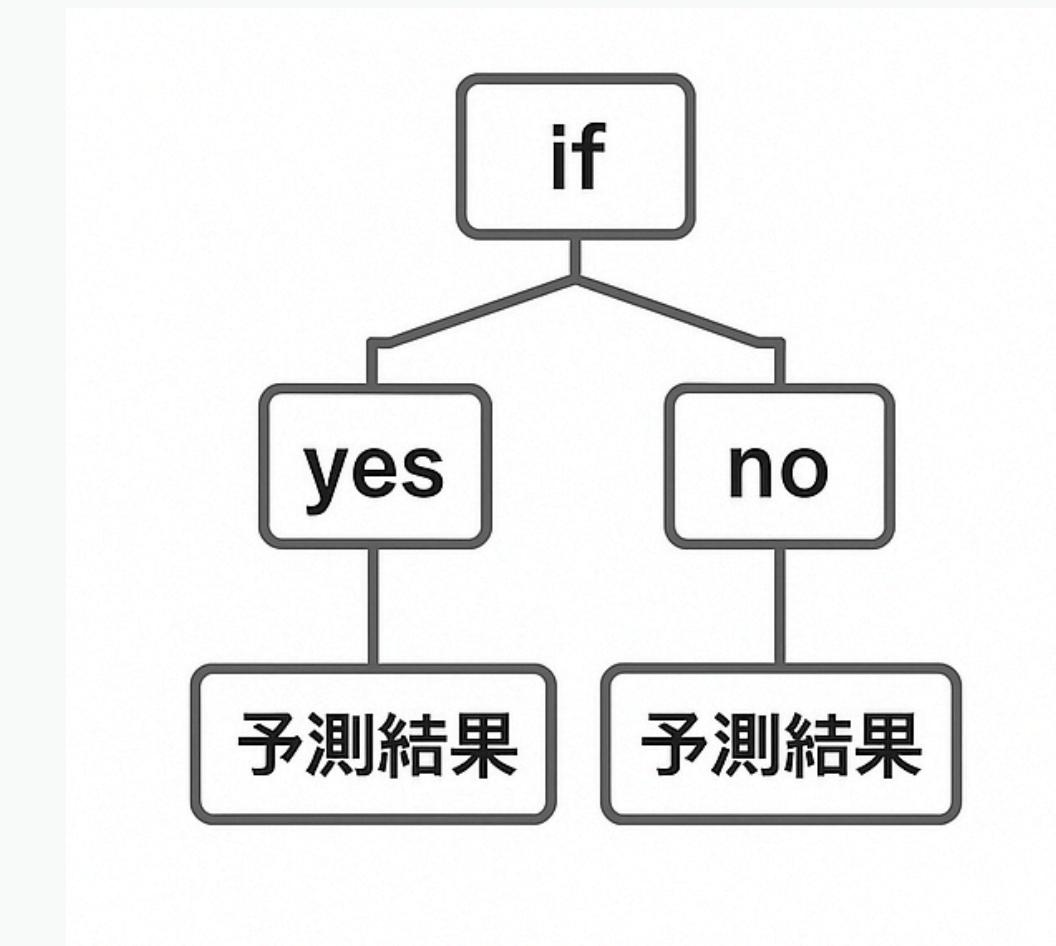
●線形系 (Logistic Regression)

- ・入力と出力の関係が直線的なモデル
 $y = ax + b$ のように表現される。
- ・非線形な関係は表現できない。



●木構造 (LightGBM)

- ・決定木集合モデル
- ・非線形な関係を表現できる



5. 各モデルの概要

- NN系 (Deep Learning 系)

● Transformer

- 自己注意機構(Self-Attention)により
系列内の重要な関係を学習
- 並列処理が可能 (RNNは順次処理)
- 長期的な依存関係に強い

どちらも「時間の流れ」や「順序のあるデータ (文章・株価など)」
を入力として扱える。

● LSTM

- RNNを改良したモデルで長期依存関係を保持
- ゲート構造を持つ
 - 忘却ゲート：古い情報をどれだけ捨てるか
 - 入力ゲート：新しい情報をどれだけ入れるか
 - 出力ゲート：どの情報を次に渡すか

5. 各モデルの概要

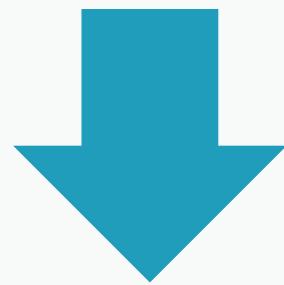
- Transformer, LSTMの入力形状

入力: $(B, T = 60, F = 36)$

B: 各フォールドのサンプル数

T: 窓幅

F: 学習に使う特徴量数



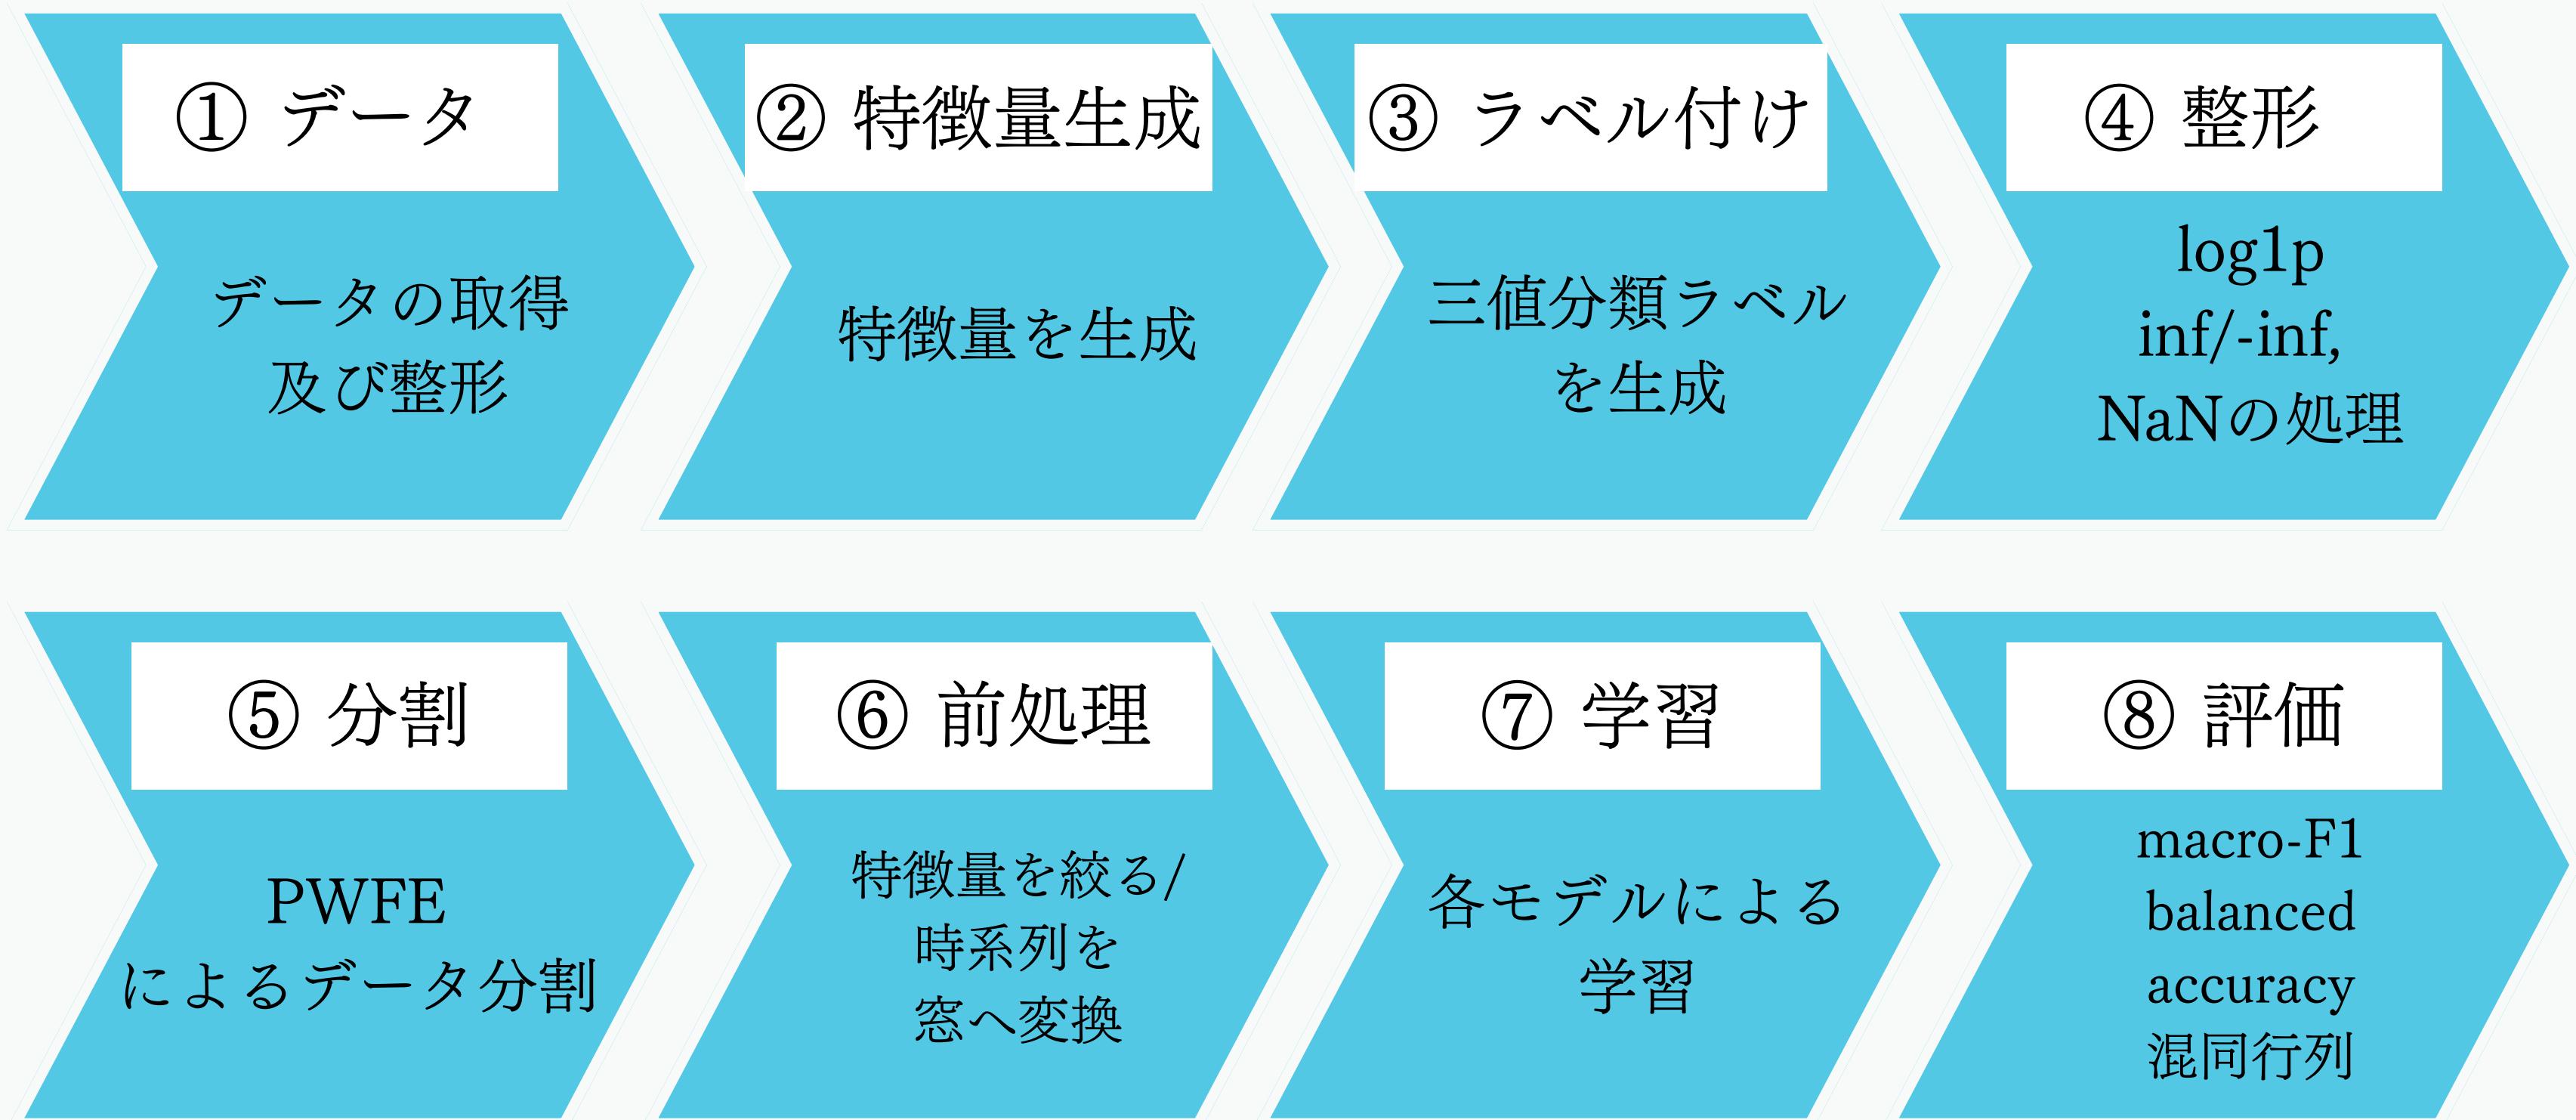
出力: $(B, 3)$

各クラスごとの確率を出力する

表3. 各フォールドごとの訓練/検証/テストデータ数

Fold	訓練データ	検証データ	テストデータ
1	785	151	1001
2	1634	363	1001
3	2483	575	1001
4	3332	787	1001

6. コード実装の概要



6. コード実装の概要（データ分割）

Purged Walk-Forward + Embargoを採用することで、
「未来リーク」「自己相関バイアス」を防ぎ、汎化性能を現実的に評価する

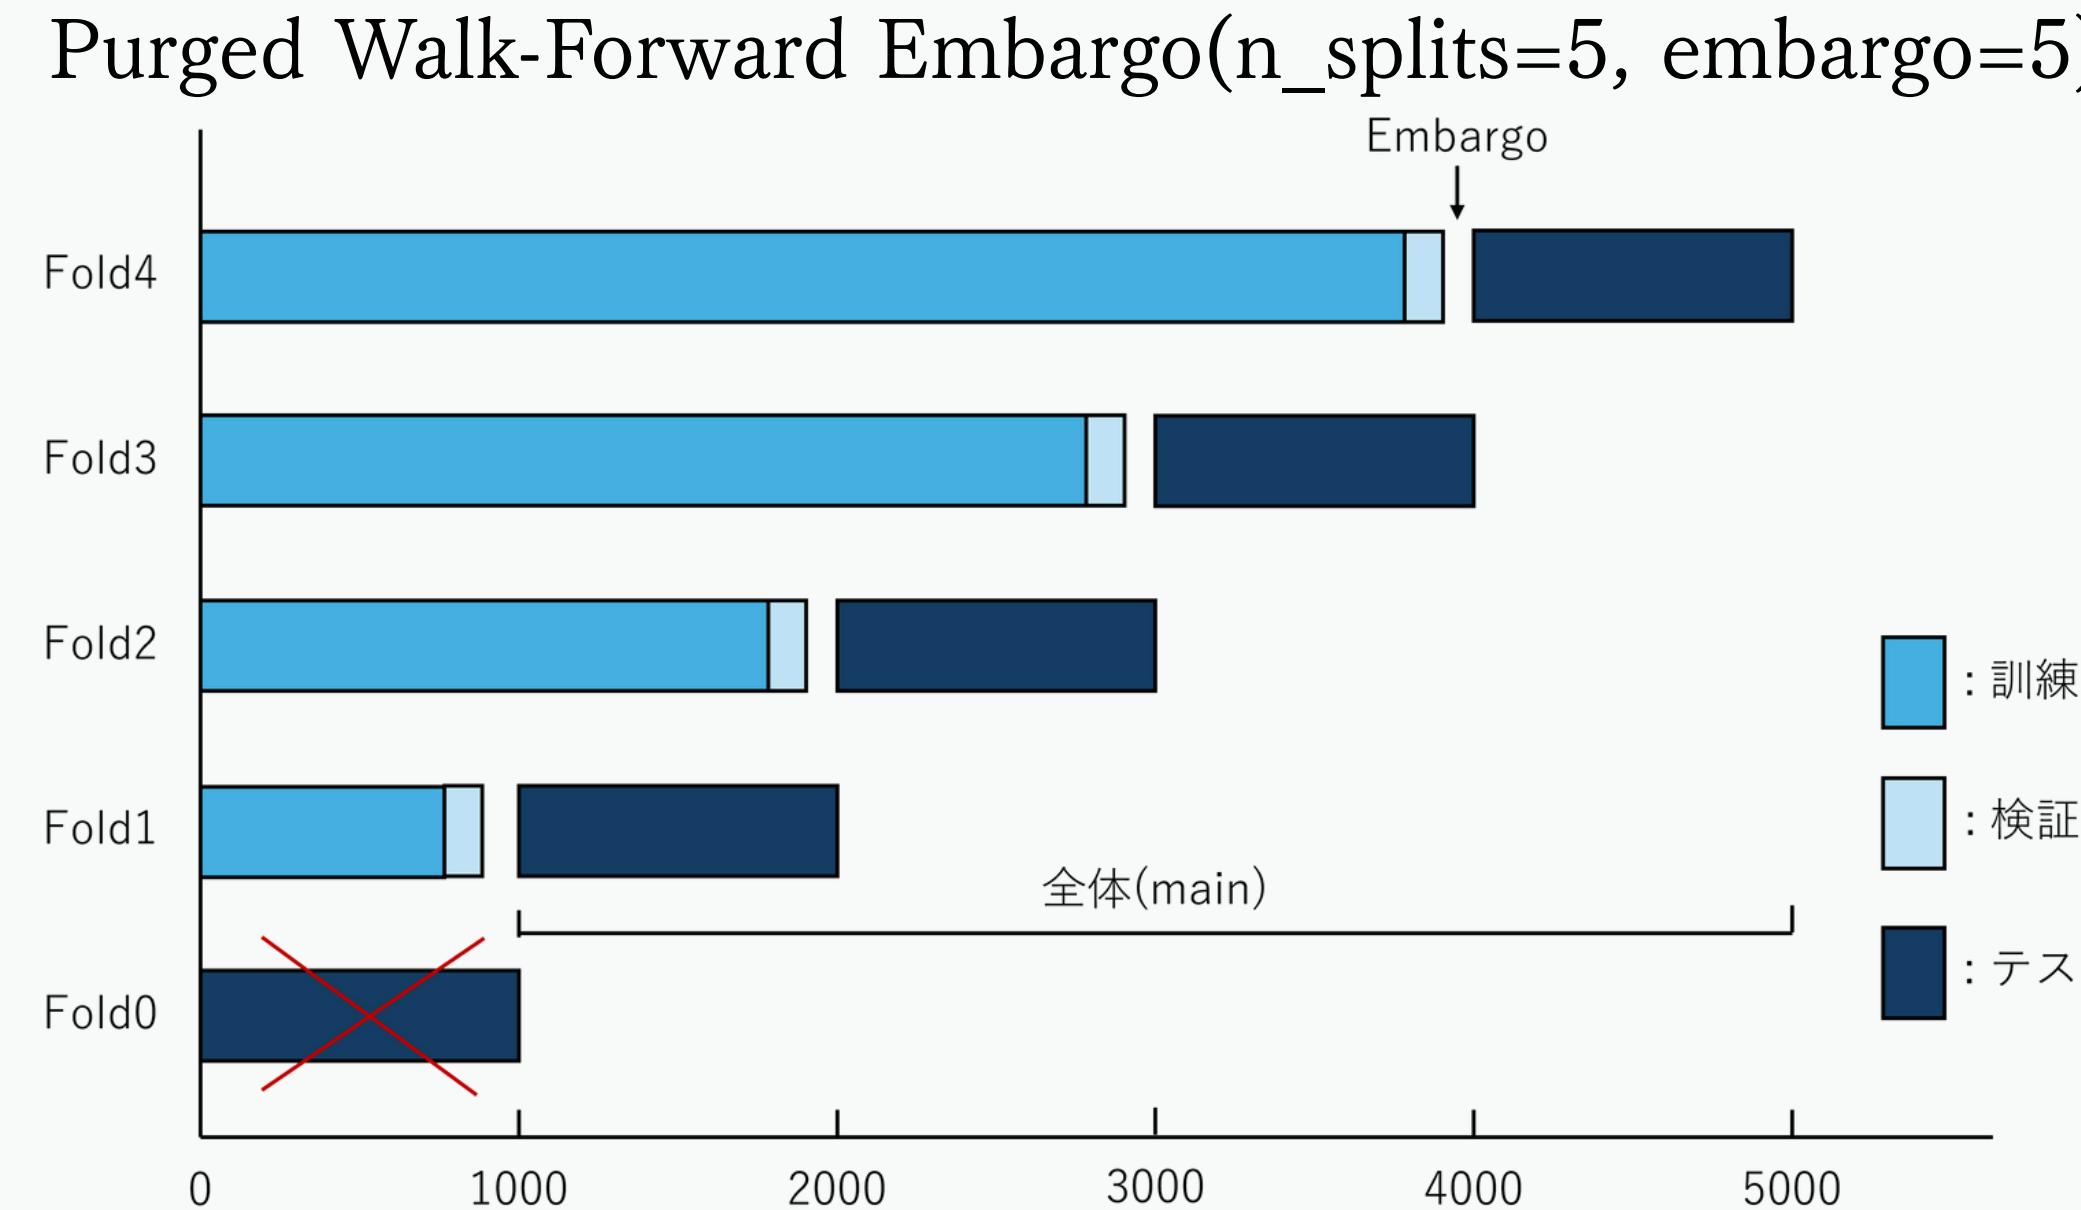


図2. データ分割

6. コード実装の概要（特徴量別重要度）

特徴量別重要度を可視化することで、どの特徴量が有用か、モデルを構成する際、取捨選択できる。

また、フェーズ2でニュースの文脈情報を特徴量として追加した際、どれほど精度に寄与したか可視化することができる。

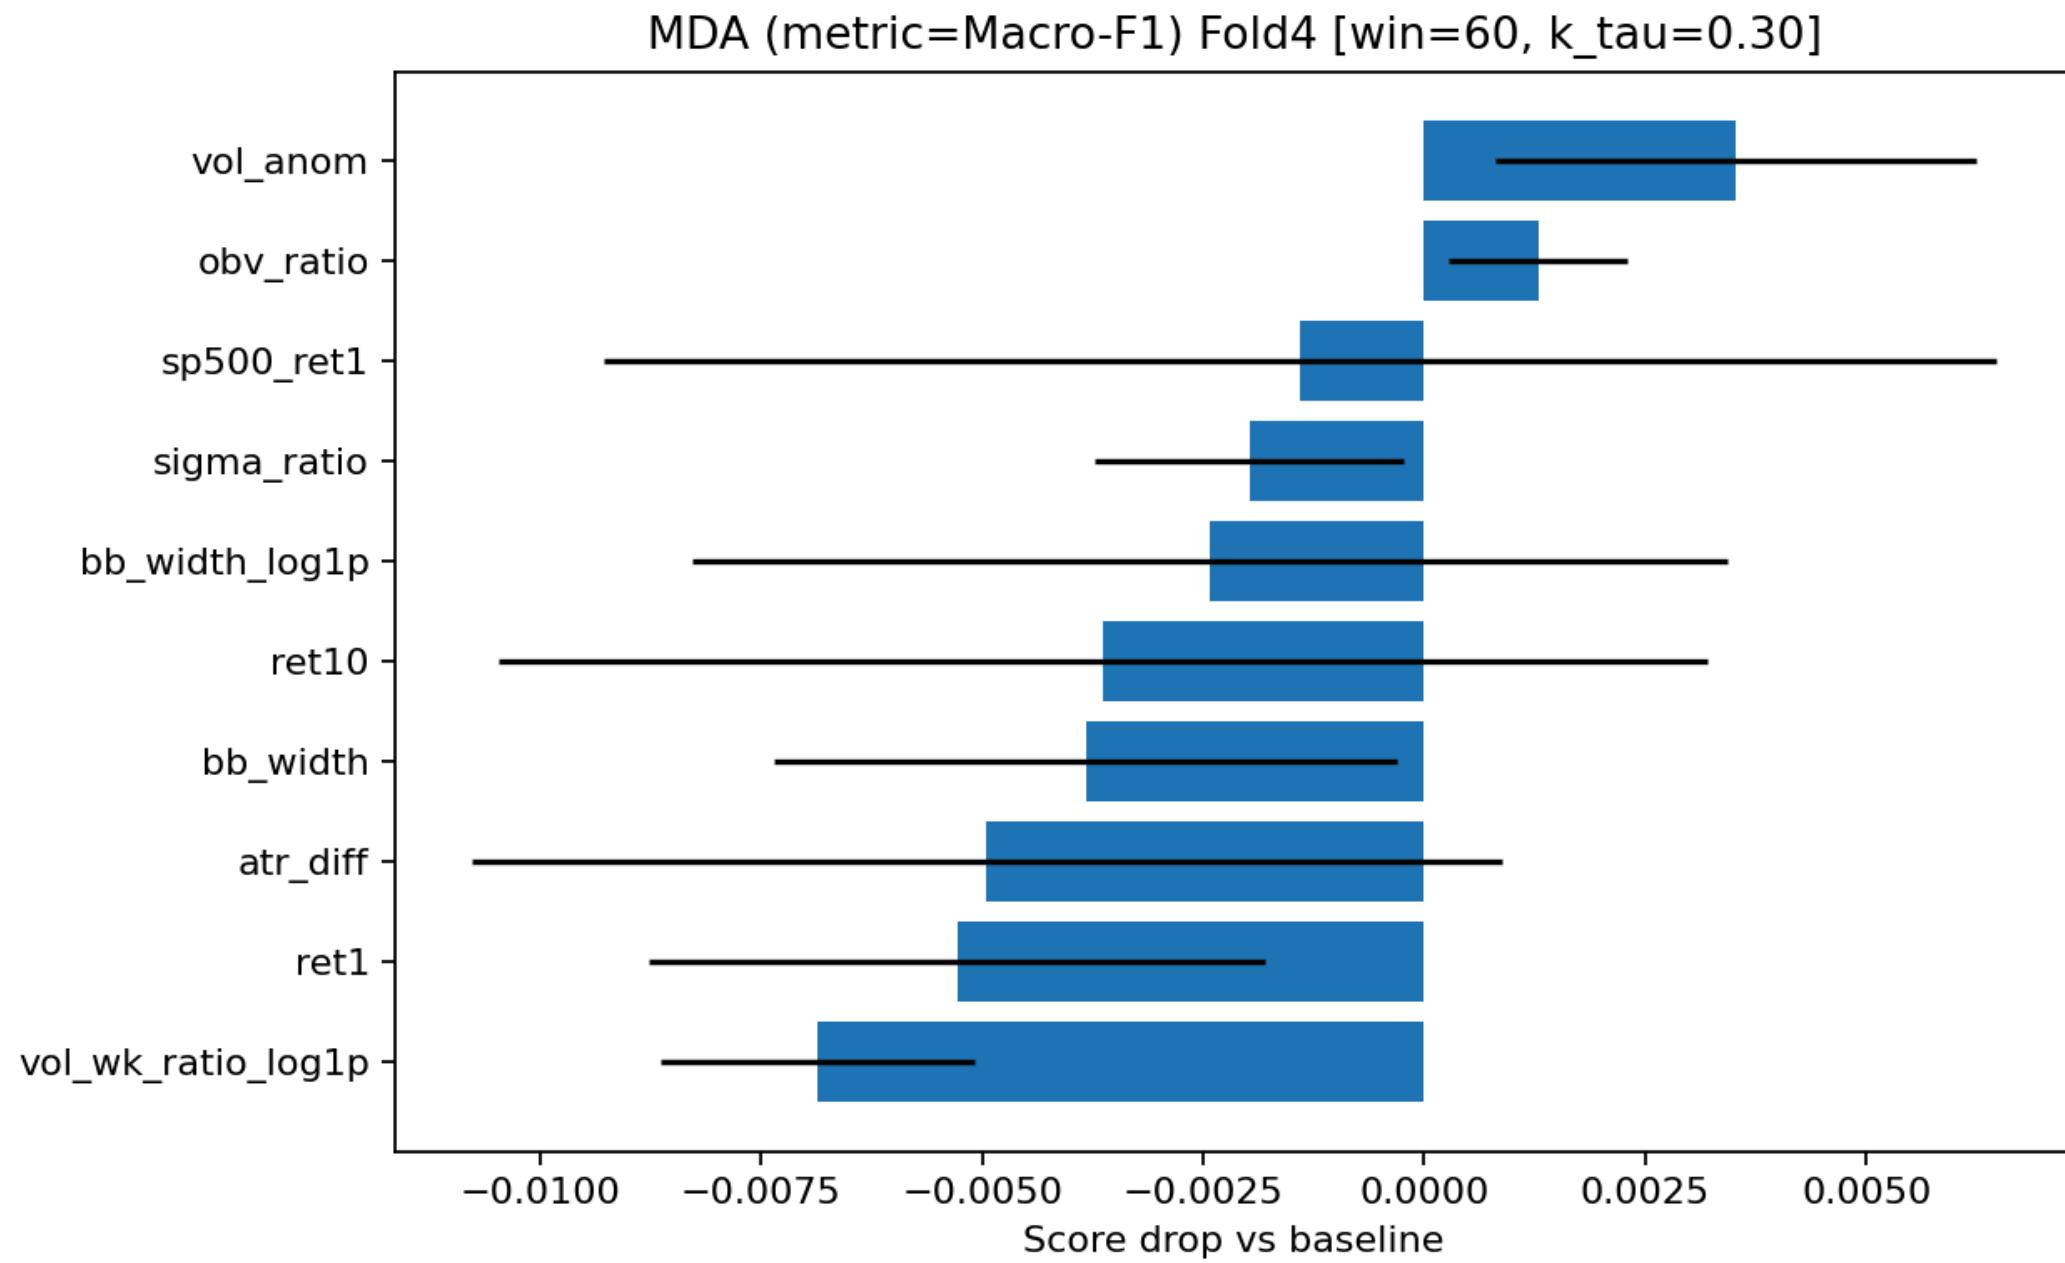
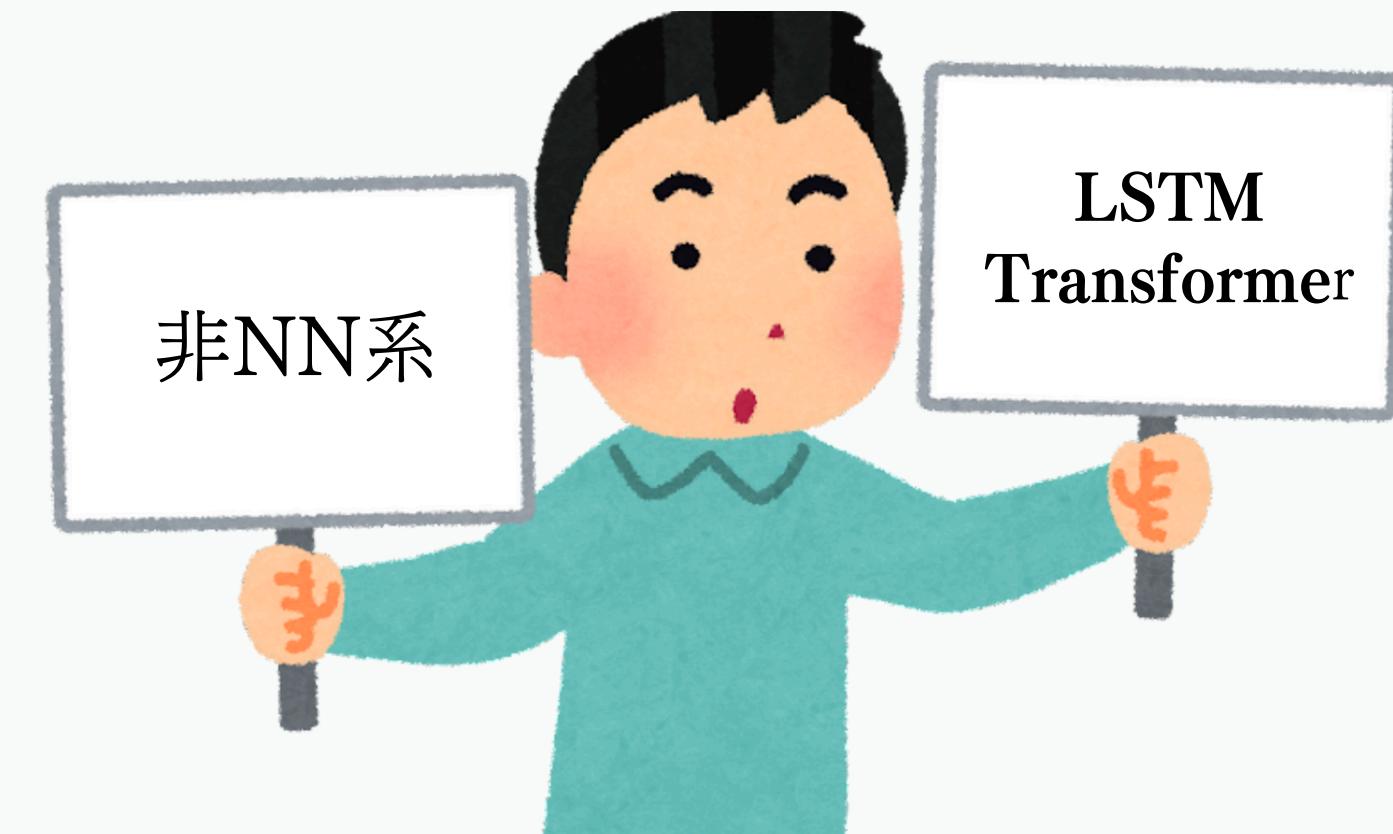


図3. transformerモデルのFold4における特徴量別重要度

7. 予想

・結果の予想

時系列データに対する学習に強いLSTMやTransformerが非NN系よりも圧倒的に精度が良いものと予想。



8. 研究結果

1. 各モデルの実行結果

表4. 実行結果 (main)

モデル	macro_f1	balanced_acc
Transformer	0.3526	0.3561
LSTM	0.3485	0.3657
LightGBM	0.3534	0.3556
Logistic_Reg	0.3258	0.3284

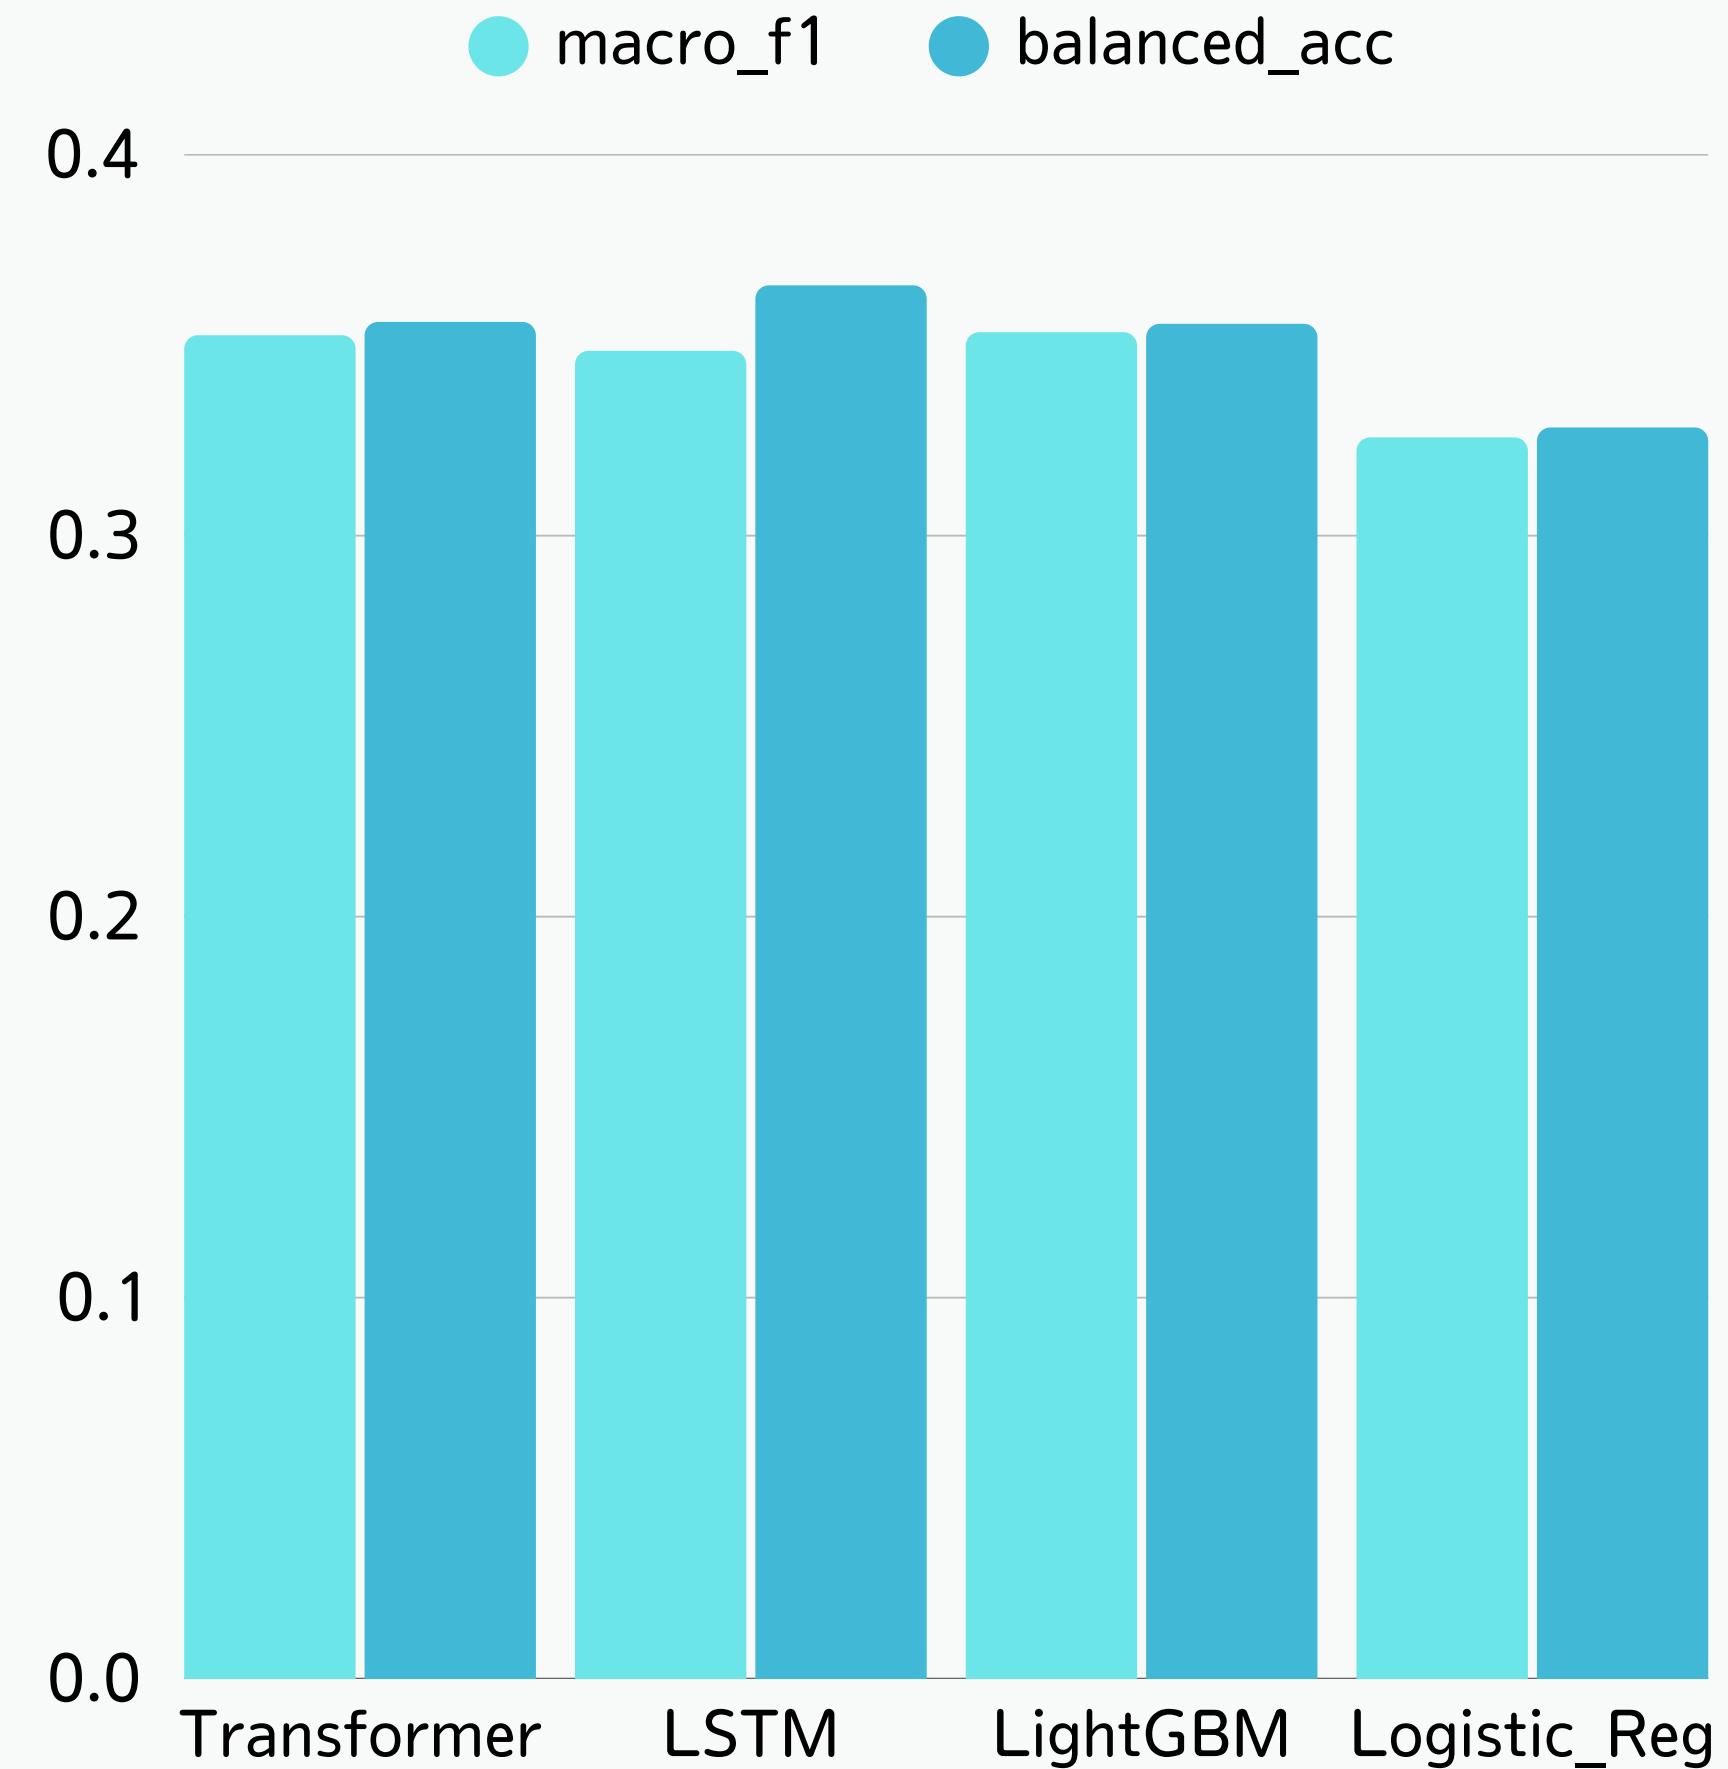


図4. 実行結果 (main)

8. 研究結果

2. 実行結果(subset)

表5. 実行結果 (subset)

モデル	macro_f1	macro_f1
Trasnformer	0.3037	0.4056
LSTM	0.2642	0.3474
LightGBM	0.2496	0.3200
Logistic_Reg	0.3106	0.4180

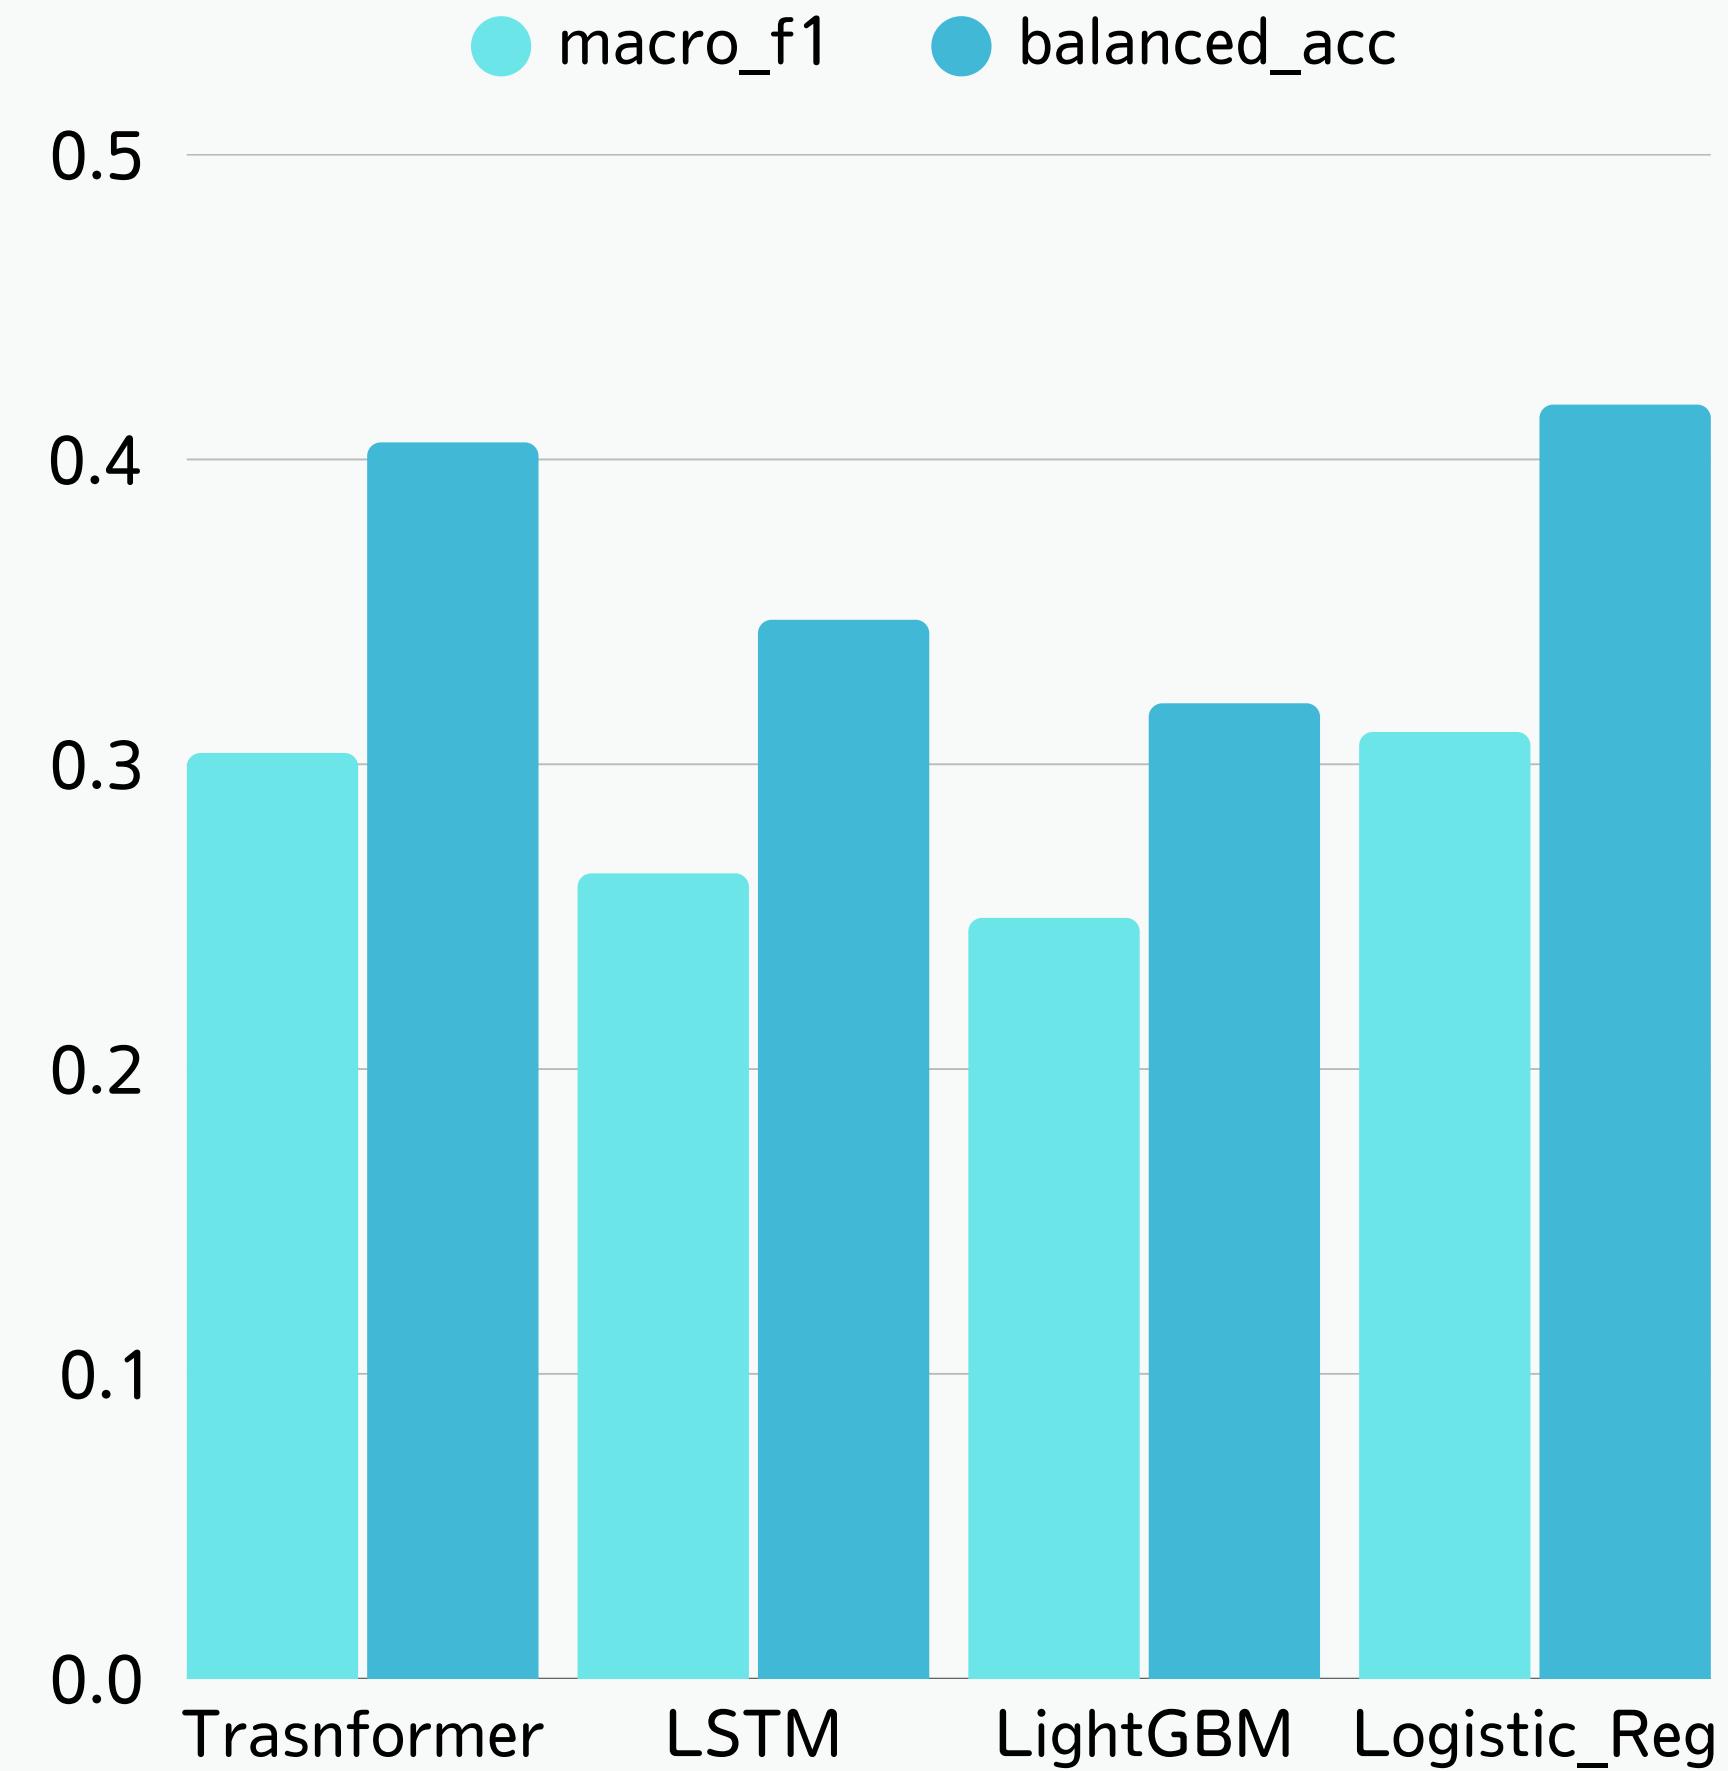


図5. 実行結果(subset)

8. 研究結果

3. 各フォールドの学習状況の可視化

学習曲線(train_lossとval_loss)およびval_accuracyをグラフとして出力

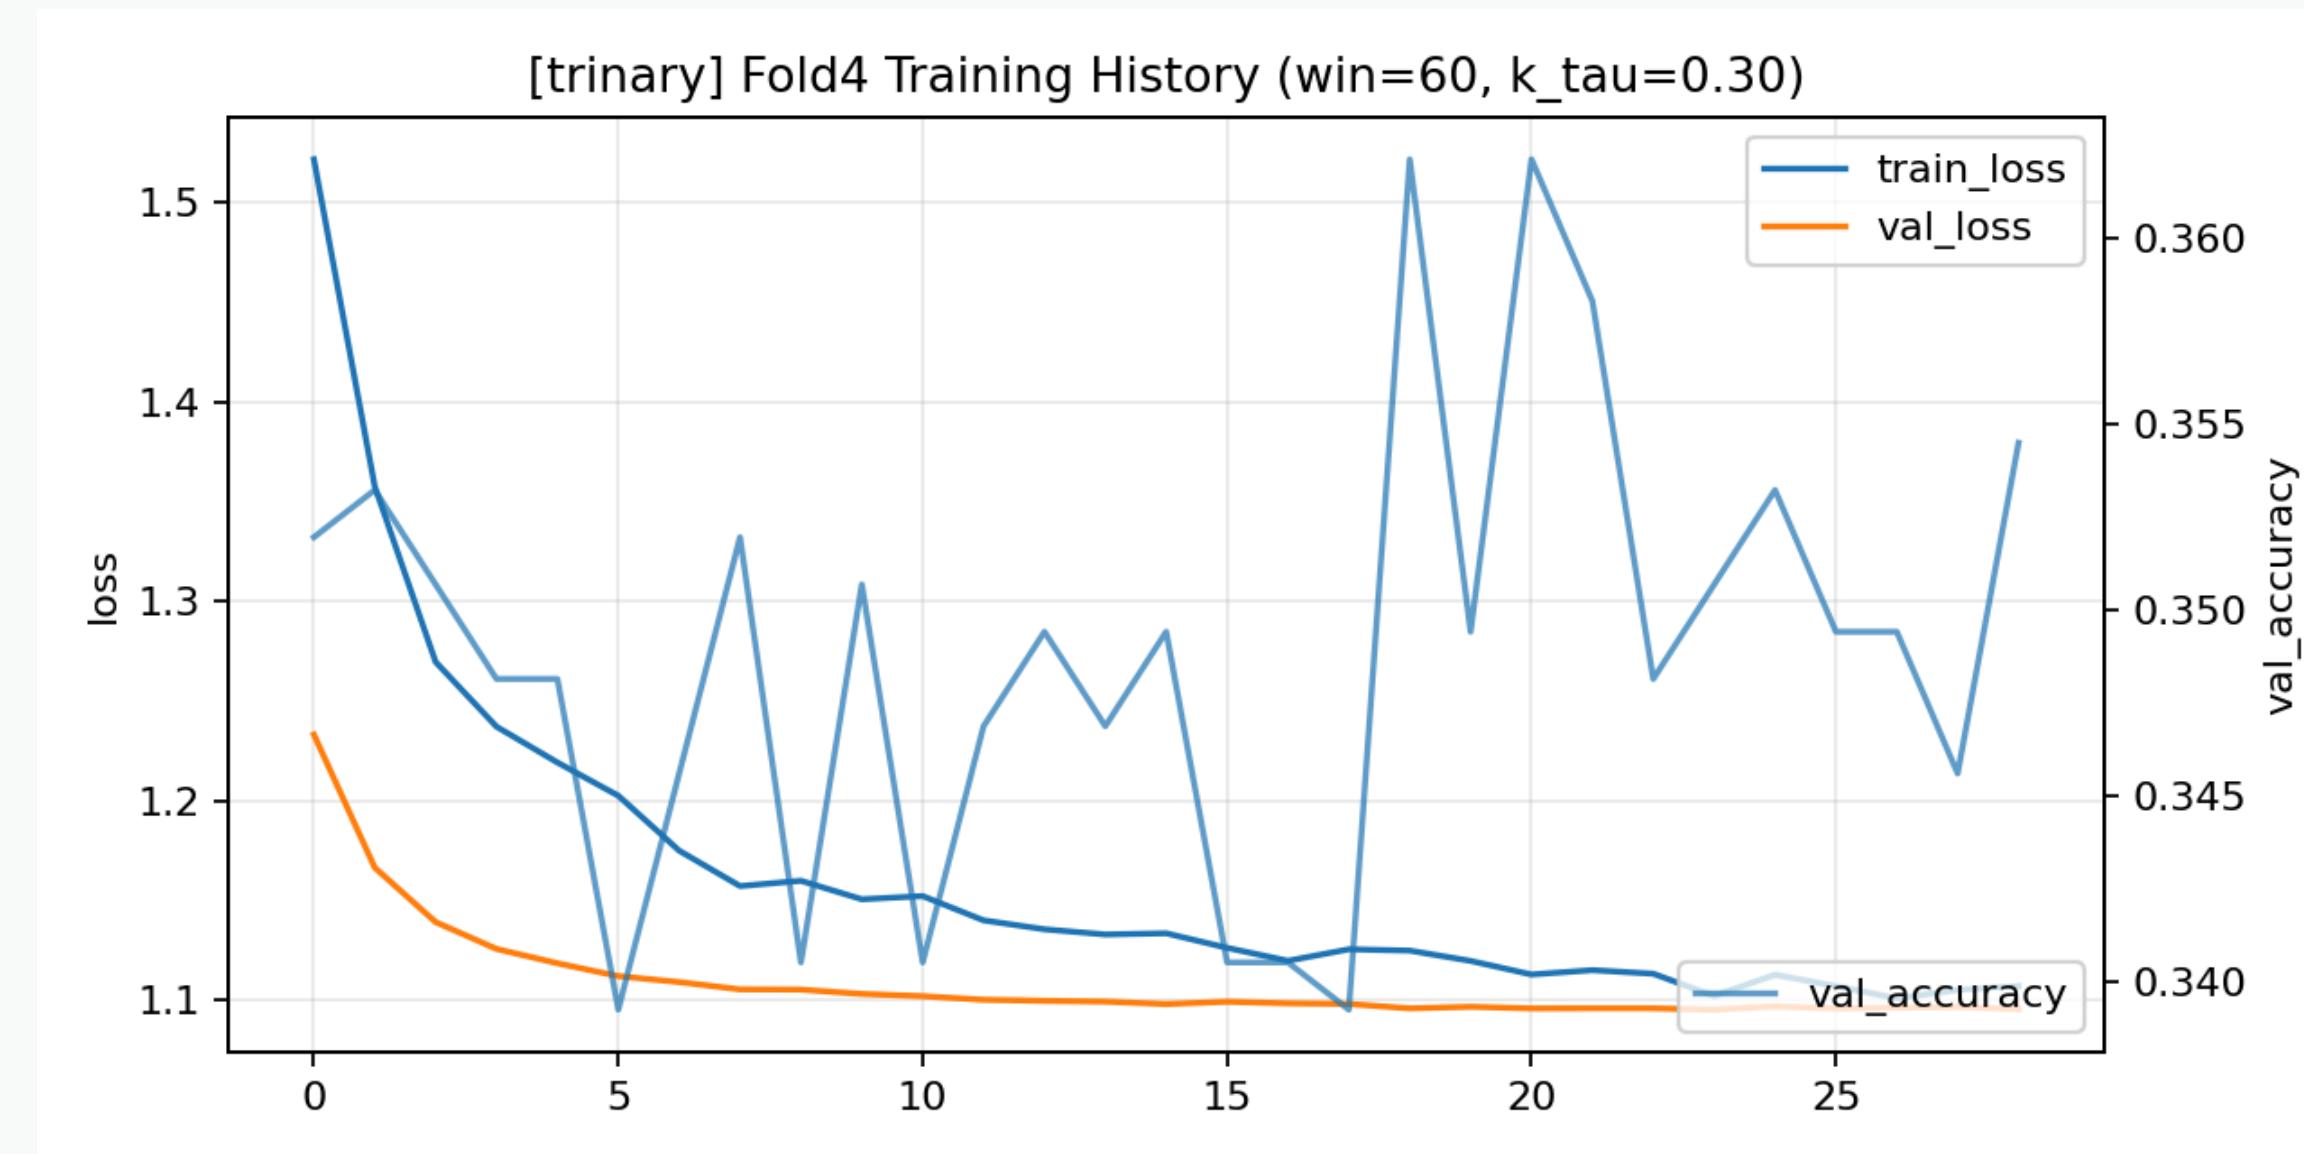


図6. transformerモデルのFold4における学習状況

9. 考察

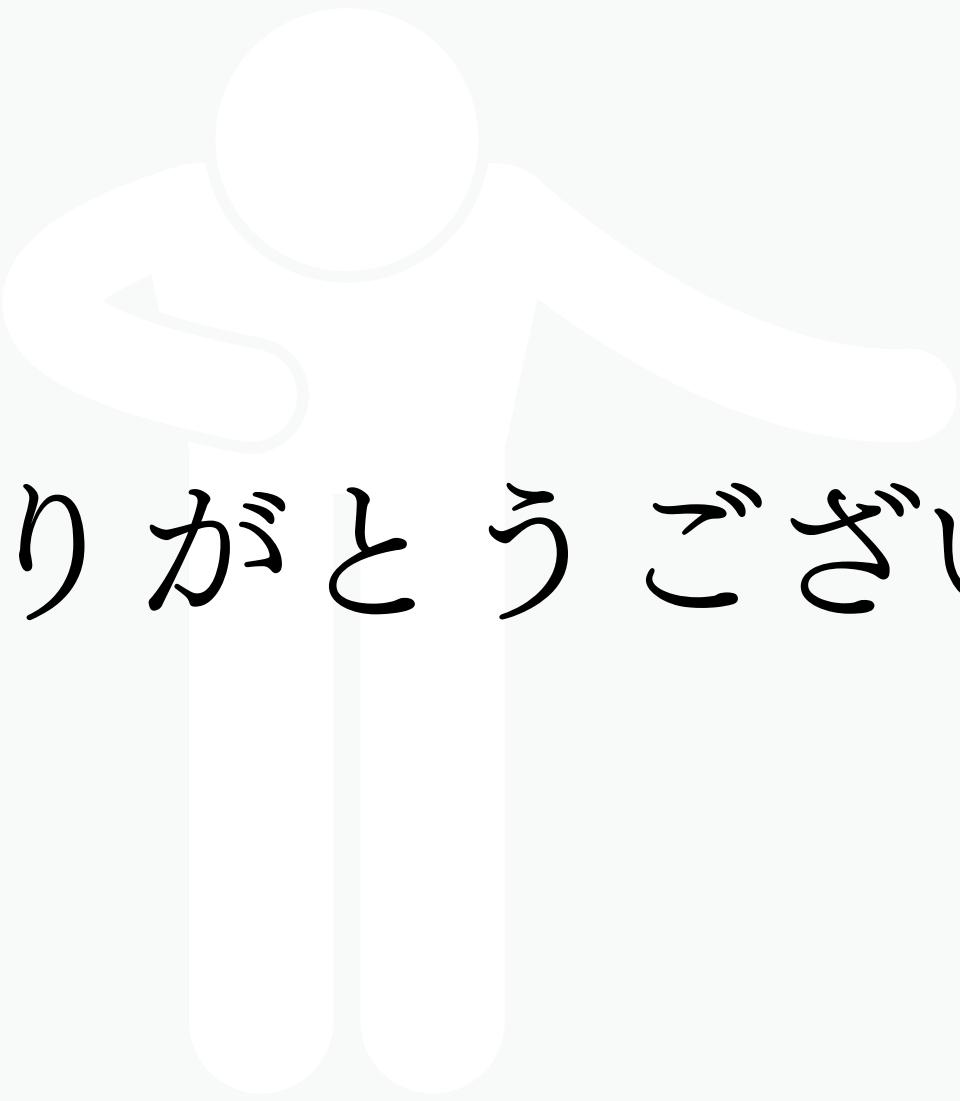
- なぜ時系列データに有効とされているNN系(LSTM, Transformer)が非NN系と横並びになっているか?
 - 特徴量が価格派生中心ばかり
 - ノイズの多さ
 - サンプルデータ数が少ない
- なぜ顕著にsubsetに対応できていないのか?
 - 閾値の未調整：mainの設定を流用しているため、subsetの特性に最適化されていない
 - 外部情報の不足：決算やイベントなど変動要因をとらえる特徴量が不足

9. 考察

- なぜsubsetで比較的TransformerとLogistic regressionが有効だったのか？
- LR：“方向手がかり”関連の特徴量の絶対値が大きくなりやすく、学習済みの直線境界に対するmargin（境界からの距離）が拡大。
- Transformer：self-attentionにより、直近の変化点や急騰区間へ重みが集中
- LightGBM：“階段関数”だから強さが連續的に増えない
- LSTM：main向けのゲート調整が影響し、時系列依存を十分活かせなかつた

10. 今後の展望

- ・NNの時系列データに対する予測精度が非NNと変わらない原因を探り、改善する。
- ・各モデルにニュースの「文脈情報」を特徴量として加えることで、汎化性能がどのくらい向上するか調べる（フェーズ2）



ご清聴ありがとうございました